Tutorial 2

Machine Learning

Nama: Zaki Raihan

NPM : 1606878505

Basic Statistics

1. Import data insurance.csv dan hitung dimensi:

```
In [31]: import pandas as pd
          insurance = pd.read_csv("Dataset Tutorial 2/insurance.csv")
          insurance.head() #Look at the head of the data (just the first few rows)
Out[31]:
                     sex
                           bmi children smoker
                                                   region
                                                              charges
              age
               19
                  female 27.900
                                            yes southwest 16884.92400
           1
               18
                    male 33.770
                                      1
                                             no
                                                 southeast
                                                           1725.55230
           2
               28
                    male 33.000
                                                           4449.46200
                                      3
                                                 southeast
               33
                    male 22.705
                                                 northwest 21984.47061
               32
                    male 28.880
                                                           3866.85520
                                                 northwest
In [33]: insurance.shape
Out[33]: (1338, 7)
```

Dengan menggunakan command insurance.shape, saya mendapatkan bahwa terdapat 1338 Row dan 7 Column pada data insurance.csv

2. Mengubah semua kolom yang berisi kategorikal data menjadi numerik. Misal "male" menjadi 0, "female" menjadi 1. Simpan data hasil perubahan ini kedalam insurance_modif.csv

```
In [2]: insurance['sex'] = insurance['sex'].map({'female': 1, 'male': 0})
In [24]:
          insurance.to_csv("insurance_modif.csv", sep=',', encoding='utf-8', index=False)
          insurance.head()
Out[24]:
                         bmi children smoker
                                                region
                                                          charges
                    1 27.900
                                         yes southwest 16884.92400
                    0 33.770
                                   1
                                              southeast
                                                        1725.55230
                    0 33.000
                                              southeast
                                                        4449.46200
              33
                    0 22.705
                                   0
                                             northwest 21984.47061
              32
                    0 28.880
                                   0
                                          no northwest 3866.85520
```

3. Melakukan random sampling sederhana pada data Insurance dimana k = 15!

In [40]: insurance.sample(n=15)
Out[40]:

	age	sex	bmi	children	smoker	region	charges
1075	32	1	29.590	1	no	southeast	4562.84210
460	49	1	36.630	3	no	southeast	10381.47870
54	40	1	28.690	3	no	northwest	8059.67910
1241	64	0	36.960	2	yes	southeast	49577.66240
1199	31	1	25.800	2	no	southwest	4934.70500
1170	18	0	27.360	1	yes	northeast	17178.68240
550	63	0	30.800	0	no	southwest	13390.55900
305	29	0	33.345	2	no	northwest	19442.35350
1174	29	0	32.110	2	no	northwest	4433.91590
1005	29	0	31.730	2	no	northwest	4433.38770
1264	49	1	33.345	2	no	northeast	10370.91255
1249	32	0	33.630	1	yes	northeast	37607.52770
996	39	1	34.100	3	no	southwest	7418.52200
548	25	1	28.595	0	no	northeast	3213.62205
783	50	1	27.600	1	yes	southwest	24520.26400

4. Melakukan uji korelasi spearman dan pearson

Variable yang saya uji korelasinya adalah pengaruh 'age' terhadap 'charges', pengaruh 'bmi' terhadap 'charges' dan pengaruh 'children' terhadap 'charges'.

Saya memilih *age*, *bmi*, dan *children* karena saya merasa ketiga variable tersebut dapat mempengaruhi besaran biaya asuransi untuk seseorang (*charges*)

Uji korelasi dengan pearson:

```
insurance_pearson__ageXcharges = insurance['charges'].corr(insurance['age'], method='pearson')
print ("Korelasi dari ages dan charges ('Pearson') = " + str(insurance_pearson__ageXcharges))
insurance_pearson__bmiXcharges = insurance['charges'].corr(insurance['bmi'], method='pearson')
print ("Korelasi dari bmi dan charges ('Pearson') = " + str(insurance_pearson__bmiXcharges))
insurance_pearson__childrenXcharges = insurance['charges'].corr(insurance['children'], method='pearson')
print ("Korelasi dari children dan charges ('Pearson') = " + str(insurance_pearson__childrenXcharges))
```

Korelasi dari ages dan charges ('Pearson') = 0.2990081933306476 Korelasi dari bmi dan charges ('Pearson') = 0.19834096883362884 Korelasi dari children dan charges ('Pearson') = 0.06799822684790487

Uji korelasi dengan spearman:

```
insurance_spearman__ageXcharges = insurance['charges'].corr(insurance['age'], method='spearman')
print ("Korelasi dari ages dan charges ('spearman') = " + str(insurance_spearman__ageXcharges))
insurance_spearman__bmiXcharges = insurance['charges'].corr(insurance['bmi'], method='spearman')
print ("Korelasi dari bmi dan charges ('spearman') = " + str(insurance_spearman__bmiXcharges))
insurance_spearman__childrenXcharges = insurance['charges'].corr(insurance['children'], method='spearman')
print ("Korelasi dari children dan charges ('spearman') = " + str(insurance_spearman__childrenXcharges))

Korelasi dari ages dan charges ('spearman') = 0.534392133771846
Korelasi dari bmi dan charges ('spearman') = 0.11939590358331147
```

5. Dari hasil pengujian korelasi terhadap variabel *age*, *bmi*, dan *children*, saya dapat melihat bahwa ketiga variabel tersebut memiliki korelasi positif terhadap besaran biaya asuransi yang dikenakan kepada seseorang (*charges*). Itu artinya jika ada peningkatan umur seseorang maka kemungkinan besaran biaya asuransi juga akan naik. Hal itu juga berlaku untuk *bmi* dan jumlah anak (*children*), walaupun kenaikannya tidak signifikan.

Regresi

1. Menggunakan data insurance_modiv.csv yang dihasilkan dari nomor 1

Korelasi dari children dan charges ('spearman') = 0.13333894319168219

```
In [19]:
          import pandas as pd
          import matplotlib.pyplot as plt
          %matplotlib inline
          insurance modif = pd.read csv("insurance modif.csv")
          insurance_modif.head() #Look at the head of the data (just the first few rows)
Out[19]:
                         bmi children smoker
                                                           charges
              age
                  sex
                                                 region
              19
                    1 27.900
                                                        16884.92400
                                              southwest
              18
                    0 33.770
                                              southeast
                                                         1725.55230
           1
                                          no
                                                         4449.46200
              28
                    0 33.000
                                              southeast
              33
                    0 22.705
                                              northwest 21984.47061
```

northwest

3866.85520

2. Memilih fitur yang digunakan sebagai model

0 28.880

32

```
feature_cols = ['age','bmi', 'children']
feature_data_in_insurance = insurance_modif[feature_cols]
label_data_in_insurance = insurance_modif['charges']
```

Saya memilih variabel *age*, *bmi*, dan *children*, karena nilai korelasinya yang cukup baik dengan variabel *charge*.

3. Menggunakan proporsi 80:20 untuk pembagian data training dan testing

Menggunakan Linear Regression untuk memprediksi nilai *charges* (data hasil prediksi tidak saya tampilkan semua):

Linear Regession

```
from sklearn.linear_model import LinearRegression
 # instantiate a new model
 linreg_insurance_modif = LinearRegression()
 # fit the model to our data
 model_linreg_insurance_modif = linreg_insurance_modif.fit(train, train_labels)
 # Trying to predict with trained machine
 preds_linreg_insurance_modif = linreg_insurance_modif.predict(test)
 # Print result
 print("Prediction: \n", preds_linreg_insurance_modif)
 Prediction:
  [13305.28945949 11801.95170145 16941.71437111 14278.42206855
   8680.25439362 16202.22349193 5555.8901083 20602.58565492
   5806.95206068 15919.03165614 10299.48549201 14221.13480456
  10676.8197114 19794.64417995 20721.14505796 18319.57207031
from sklearn import metrics
import numpy as np
# Count the MSE result from prediction with real label
print("Nilai MSE = ",metrics.mean_squared_error(test_labels, preds_linreg_insurance_modif))
print("Nilai MAE = ",metrics.mean_absolute_error(test_labels, preds_linreg_insurance_modif))
print("Nilai RMSE = ",np.sqrt(metrics.mean_squared_error(test_labels, preds_linreg_insurance_modif)))
Nilai MSE = 131201335.64669803
Nilai MAE = 9181.311632897381
Nilai RMSE = 11454.315153980095
```

Menggunakan DecisionTree Regressor untuk memprediksi nilai *charges* (data hasil prediksi tidak saya tampilkan semua):

Decision Tree Regression

```
from sklearn.tree import DecisionTreeRegressor
 import matplotlib.pyplot as plt
 # instantiate a new model
 decision tree insurance modif = DecisionTreeRegressor(max depth=3)
 # fit the model to our data
 model_decision_tree_insurance_modif = decision_tree_insurance_modif.fit(train, train_labels)
 # Trying to predict with trained machine
 preds decision tree insurance modif = decision tree insurance modif.predict(test)
 # Print result
 print("Prediction: \n", preds_decision_tree_insurance_modif)
   [13781.82333455 13637.03278352 19298.06688318 13781.82333455
   13637.03278352 13637.03278352 5810.56448786 18855.02785446
    9292.19528304 13781.82333455 9292.19528304 13637.03278352
# Count the MSE result from prediction with real label
print("Nilai MSE = ",metrics.mean_squared_error(test_labels, preds_decision_tree_insurance_modif))
print("Nilai MAE = ",metrics.mean_absolute_error(test_labels, preds_decision_tree_insurance_modif))
print("Nilai RMSE = ",np.sqrt(metrics.mean_squared_error(test_labels, preds_decision_tree_insurance_modif)))
Nilai MSE = 133418362.76556465
Nilai MAE = 9292.024354617219
Nilai RMSE = 11550.6866793955
```

4. Dari hasil perhitungan menggunakan linear regression dan decision tree regressor, maka terlihat bahwa hasil MAE dari linear regression lebih kecil ketimbang menggunakan decision tree regressor.

Klasifikasi

1. menggunakan data adults.csv dan melakukan perubahan kolom yang berisi kategorikal data ke numerik



	age	workclass	fnlwgt	education	education- num	marital- status	occupation	relationship	race	sex	capital- gain	capital- loss	hours- per-week	native- country	class
0	39	State-gov	77516	Bachelors	13	Never- married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United- States	<=50K
1	50	Self-emp- not-inc	83311	Bachelors	13	Married-civ- spouse	Exec- managerial	Husband	White	Male	0	0	13	United- States	<=50K
2	38	Private	215646	HS-grad	9	Divorced	Handlers- cleaners	Not-in-family	White	Male	0	0	40	United- States	<=50K
3	53	Private	234721	11th	7	Married-civ- spouse	Handlers- cleaners	Husband	Black	Male	0	0	40	United- States	<=50K
4	28	Private	338409	Bachelors	13	Married-civ- spouse	Prof-specialty	Wife	Black	Female	0	0	40	Cuba	<=50K

```
adults['class'].describe()
adults['class'] = adults['class'].map({'<=50K': 0, '>50K': 1})
adults['sex'] = adults['sex'].map({'Female': 0, 'Male': 1})
adults['workclass'] = adults['workclass'].map({'Private': 0, 'Self-emp-not-inc': 1, 'Self-emp-inc': 2, 'Federal-gov': 3, 'Local-gadults['race'] = adults['race'].map({'White': 0, 'Black': 4, 'Asian-Pac-Islander': 1, 'Amer-Indian-Eskimo': 2, 'Other': 3})
adults['occupation'] = adults['occupation'].map({"Tech-support": 0, "Craft-repair": 1, "Other-service": 2, "Sales": 3, "Exec-madults['marital-status'] = adults['marital-status'].map({"Married-civ-spouse": 0, "Divorced": 1, "Never-married": 2, "Separate adults['relationship'] = adults['relationship'].map({"Wife": 0, "Own-child": 1, "Husband": 2, "Not-in-family": 3, "Other-relationship'].map({"Wife": 0, "Own-child": 1, "Wife": 0, "O
```

	age	workclass	fnlwgt	education	education- num	marital- status	occupation	relationship	race	sex	capital- gain	capital- loss	hours-per- week	native- country	class
0	39	5.0	77516	Bachelors	13	2	8.0	3	0	1	2174	0	40	United- States	0
1	50	1.0	83311	Bachelors	13	0	4.0	2	0	1	0	0	13	United- States	0
2	38	0.0	215646	HS-grad	9	1	6.0	3	0	1	0	0	40	United- States	0
3	53	0.0	234721	11th	7	0	6.0	2	4	1	0	0	40	United- States	0
4	28	0.0	338409	Bachelors	13	0	5.0	0	4	0	0	0	40	Cuba	0

^{*}note: jika gambar kurang jelas dapat melihat Tutorial 2 - Klasifikasi.ipynb yang telah disertakan

2. mamiilih fitur yang akan digunakan sebagai model

Saya memilih *age*, *education-num* (representasi dari *education*), *capital-gain*, dan *hours-perweek* sebagai vitur yang saya gunakan untuk mengklasifikasikan tingkatan pendapatan seseorang atau class(<=50K ataupun >50K)

Saya memilih keempat fitur tersebut karena memiliki korelasi yang cukup kuat dengan variabel class, hal itu terlihat dari perhitungan korelasi dengan menggunakan pearson dan spearman di bawah:

Pearson:

	age	workclass	fnlwgt	education- num	marital- status	occupation	relationship	race	sex	capital- gain	capital- loss	hours-per- week	class
age	1.0	0.12	-0.077	0.037	-0.22	0.021	0.13	-0.03	0.089	0.078	0.058	0.069	0.23
workclass	0.12	1.0	-0.022	0.081	0.011	0.13	-0.019	0.038	-0.047	0.0012	0.0068	-0.09	0.015
fnlwgt	-0.077	-0.022	1.0	-0.043	0.024	0.0039	0.015	0.098	0.027	0.00043	-0.01	-0.019	-0.0095
education- num	0.037	0.081	-0.043	1.0	-0.11	-0.037	-0.032	-0.079	0.012	0.12	0.08	0.15	0.34
marital-status	-0.22	0.011	0.024	-0.11	1.0	0.017	0.36	0.13	-0.38	-0.074	-0.067	-0.22	-0.38
occupation	0.021	0.13	0.0039	-0.037	0.017	1.0	0.011	0.042	-0.044	-0.012	-0.015	0.04	-0.045
relationship	0.13	-0.019	0.015	-0.032	0.36	0.011	1.0	0.12	-0.17	-0.027	-0.031	0.057	-0.17
race	-0.03	0.038	0.098	-0.079	0.13	0.042	0.12	1.0	-0.12	-0.02	-0.024	-0.054	-0.097
sex	0.089	-0.047	0.027	0.012	-0.38	-0.044	-0.17	-0.12	1.0	0.048	0.046	0.23	0.22
capital-gain	0.078	0.0012	0.00043	0.12	-0.074	-0.012	-0.027	-0.02	0.048	1.0	-0.032	0.078	0.22
capital-loss	0.058	0.0068	-0.01	0.08	-0.067	-0.015	-0.031	-0.024	0.046	-0.032	1.0	0.054	0.15
hours-per- week	0.069	-0.09	-0.019	0.15	-0.22	0.04	0.057	-0.054	0.23	0.078	0.054	1.0	0.23
class	0.23	0.015	-0.0095	0.34	-0.38	-0.045	-0.17	-0.097	0.22	0.22	0.15	0.23	1.0

Spearman:

	age	workclass	fnlwgt	education- num	marital- status	occupation	relationship	race	sex	capital- gain	capital- loss	hours-per- week	class
age	1.0	0.17	7 -0.078 0.066 -		-0.36	0.019	0.17	-0.028	0.1	0.12	0.058	0.14	0.27
workclass	0.17	1.0	-0.04	0.11	-0.06	0.095	-0.024	0.015	0.0065	0.031	0.019	-0.024	0.059
fnlwgt	-0.078	-0.04	1.0	-0.036	0.032	0.0046	0.012	0.054	0.025	-0.006	-0.0069	-0.022	-0.011
education- num	0.066	0.11	-0.036	1.0	-0.096	0.0098	-0.0037	-0.058	0.0063 0.	0.12	0.075	0.17	0.33
marital-status	-0.36	-0.06	0.032	-0.096	1.0	0.022	0.37	0.13	-0.4	-0.13	-0.074	-0.26	-0.42
occupation	0.019	0.095	0.0046	0.0098	0.022	1.0	0.011	0.031	-0.064	0.00098	-0.01	0.027	-0.027
relationship	0.17	-0.024	0.012	-0.0037	0.37	0.011	1.0	0.089	-0.16	-0.029	-0.022	0.066	-0.16
race	-0.028	0.015	0.054	-0.058	0.13	0.031	0.089	1.0	-0.11	-0.03	-0.021	-0.08	-0.088
sex	0.1	0.0065	0.025	0.0063	-0.4	-0.064	-0.16	-0.11	1.0	0.067	0.042	0.26	0.22
capital-gain	0.12	0.031	-0.006	0.12	-0.13	0.00098	-0.029	-0.03	0.067	1.0	-0.067	0.093	0.28
capital-loss	0.058	0.019	-0.0069	0.075	-0.074	-0.01	-0.022	-0.021	0.042	-0.067	1.0	0.06	0.14
hours-per- week	0.14	-0.024	-0.022	0.17	-0.26	0.027	0.066	-0.08	0.26	0.093	0.06	1.0	0.27
class	0.27	0.059	-0.011	0.33	-0.42	-0.027	-0.16	-0.088	0.22	0.28	0.14	0.27	1.0

3. Menggunakan proporsi 80:20 untuk melakukan pembagian data training dan testing.

Menggunakan algoritma Decision Tree untuk melakukan pengelompokkan class di data tersebut.

```
from sklearn.tree import DecisionTreeClassifier
import matplotlib.pyplot as plt

# instantiate a new model
decision_tree_adults = DecisionTreeClassifier(max_depth=4, random_state=1)

# fit the model to our data
model_decision_tree_adults = decision_tree_adults.fit(train, train_labels)


# Trying to predict with trained machine
preds_decision_tree_adults = decision_tree_adults.predict(test)

# Print result
pd.DataFrame({'feature':feature_cols, 'importance':decision_tree_adults.feature_importances_})
```

	feature	importance
0	age	0.211062
1	education-num	0.244790
2	capital-gain	0.480501
3	hours-per-week	0.063646

4. Visualisasi dari confussion matrix hasil klasifikasi:

Confusion matrix of the classifier



5. Akurasi, precision dan recall pada hasil klasifikasi model:

```
accuracy score: 0.8229694457239367
```

```
precision score:
   0.75
```

recall score: 0.39910884786760026

Code untuk menampilkan confussion matrix, akurasi, precision dan recall:

Confussion Matrix:

Akurasi, precision dan recall:

```
from sklearn.metrics import accuracy_score
from sklearn.metrics import precision_score
from sklearn.metrics import recall_score

print('accuracy score: \n', accuracy_score(test_labels, preds_decision_tree_adults))
print("\n")
print('precision score: \n', precision_score(test_labels, preds_decision_tree_adults))
print("\n")
print('recall score: \n', recall_score(test_labels, preds_decision_tree_adults))
```


6. Penjelasan mengenai interpretasi hasil evaluasi dan error analysis.

Berdasarkan confussion matrix terlohat bahwa:

- Banyaknya data diprediksi termasuk dalam kelas <=50K dan kenyataannya benar termasuk kelas <=50K adalah sebanyak: 4733 data
- Banyaknya data diprediksi termasuk dalam kelas <=50K dan kenyataannya termasuk kelas >50K adalah sebanyak: 944 data
- Banyaknya data diprediksi termasuk dalam kelas >50K dan kenyataannya benar termasuk kelas >50K adalah sebanyak: 627 data
- Banyaknya data diprediksi termasuk dalam kelas >50K dan kenyataannya termasuk kelas <=50K adalah sebanyak: 209 data
- Dari sini dapat dilihat bahwa peluang perkiraan benar sekitar: (4733+627)/6513 = 0.82 atau 82%, sesuai dengan accuracy score

Clustering

1. Menggunakan data water-treatment.csv sebagai input data untuk clustering.




	Date	Q-E	ZN- E	PH- E	DBO-E	DQO- E	SS-E	SSV- E	SED- E	COND- E	 COND- S	RD-DBO- P	RD- SS- P	SED- P	RD-DBO- S	DQO- S	RD-DBO- G	DQO- G	SS- G	SEC
0	D- 1/3/90	44101.0	1.5	7.8	188.714286	407.0	166.0	66.3	4.5	2110	 2000.0	39.085806	58.8	95.5	83.448049	70.0	89.013646	79.4	87.3	99.
1	D- 2/3/90	39024.0	3.0	7.7	188.714286	443.0	214.0	69.2	6.5	2660	2590.0	39.085806	60.7	94.8	83.448049	80.8	89.013646	79.5	92.1	100.
2	D- 4/3/90	32229.0	5.0	7.6	188.714286	528.0	186.0	69.9	3.4	1666	1888.0	39.085806	58.2	95.6	83.448049	52.9	89.013646	75.8	88.7	98.
3	D- 5/3/90	35023.0	3.5	7.9	205.000000	588.0	192.0	65.6	4.5	2430	1840.0	33.100000	64.2	95.3	87.300000	72.3	90.200000	82.3	89.6	100.
4	D-	36924 N	1.5	8.0	242 000000	496 N	176 N	64.8	4.0	2110	2120.0	39 085806	62.7	95.6	83 448049	71 0	92 100000	78.2	27 5	99

*note: saya melakukan persiapan data (data preparation) dengan asumsi bahwa data dengan '?' merupakan data yang tidak diketahui nilainya dan saya ganti dengan menggunakan rata2 dari kolom yang bersangkutan (jia '?' berada kolom Q-E maka nilainya saya ganti dengan ratarata nilai Q-E)

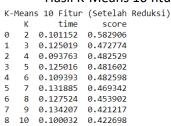
2. Apakah anda memerlukan reduksi dimensi pada data tersebut?, Jika Iya berapa jumlah fitur yang anda gunakan dan berapa jumlah fitur yang anda hilangkan?
Saya melakukan reduksi dengan menggunakan feature extraction dengan menggunakan modul PCA, dengan begitu maka tidak ada fitur yang dihilangkan melainkan saya menggabungkannya sehingga total hanya ada 10 fitur dari 38 fitur awal

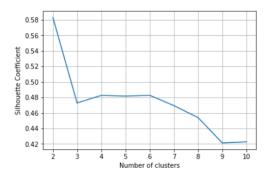
3. Hasil K-Means semua fitur:

K-Means Semua Fitur



Hasil K-Means 10 fitur





4. Dari perbandingan kedua tabel hasil perhitungan K-Means untuk model diatas terlihat bahwa jika kita melakukan feature extraction maka waktu yang kita butuhkan akan lebih cepat ketimbang menggunakan semua fitur yang ada namun tidak begitu memiliki pengaruh yang berarti pada nilai Sihoulette Coeficientnya, sehingga dapat disimpulkan bahwa menggunakan feature extraction lebih efisien ketimbang menggunakan seluruh fitur yang ada.